

Projekt Dyplomowy 2026- raport postępu prac

Wyznaczanie poziomów Fibonacciego pod kątem możliwego zastosowania
w modelach klasyfikacyjnych.

Paweł Myszka
nr albumu: 331720

21 kwietnia 2026

Spis treści

1	Cel projektu	2
2	Przegląd literatury i podstawy teoretyczne	2
3	Postęp prac – status etapów	3
4	Opis zrealizowanych etapów	3
4.1	Pobranie i oczyszczenie danych cenowych	3
4.2	Wyznaczenie lokalnych minimów i maksimów (swing points)	4
4.3	Wyznaczanie trendów wzrostu i spadku	4
4.4	Wyznaczenie poziomów Fibonacciego i generowanie stref	4
4.5	Etykietowanie stref	4
4.6	Cechy wejściowe modelu klasyfikacyjnego	4
4.6.1	Cechy trendu źródłowego	4
4.6.2	Cechy odległości i położenia ceny	5
4.6.3	Cechy wolumenu	6
4.6.4	Wskaźniki techniczne	6
4.6.5	Cechy Fibonacciego	7
4.6.6	Podsumowanie ważności cech	7
4.7	Podział danych i oversampling	8
4.8	Trening i porównanie modeli klasyfikacyjnych	8
5	Aktualny problem: dysproporcja klas	9
6	Planowane dalsze kroki	9
6.1	Rozszerzenie zbioru danych	9
6.2	Sieci neuronowe	10
6.3	Dalsze kroki metodologiczne	10
7	Podsumowanie	10

1 Cel projektu

Celem projektu jest zbadanie, czy poziomy Fibonacciego wyznaczone na podstawie lokalnych ekstremów cenowych mogą stanowić użyteczne cechy wejściowe dla modeli klasyfikacyjnych w kontekście analizy technicznej rynków finansowych. Projekt ma na celu stworzenie systemu automatycznego wyznaczania stref wsparcia i oporu opartych na geometrii Fibonacciego, a następnie klasyfikację tych stref jako *trafione* lub *nietrafione* przez algorytmy uczenia maszynowego.

2 Przegląd literatury i podstawy teoretyczne

Podstawę teoretyczną projektu stanowią narzędzia analizy technicznej wywodzące się z ciągu Fibonacciego oraz złotego podziału. Kluczową pozycją literaturową jest:

Paweł Danielewicz, *Geometria Fibonacciego* – literatura poświęcona zastosowaniu współczynników Fibonacciego w analizie rynków finansowych. Autor szczegółowo omawia konstruowanie stref wsparcia i oporu oraz interpretację zachowania ceny w okolicach kluczowych poziomów (0,236; 0,382; 0,5; 0,618; 0,786; 1,0; 1,272; 1,618 i inne).

W projekcie zastosowano rozszerzony zestaw poziomów Fibonacciego zgodny z podejściem prezentowanym przez Danielewicza:

$$L = \{0; 0,236; 0,278; 0,38; 0,44; 0,5; 0,577; 0,61; 0,667; 0,707; 0,77; 0,786; 0,8; 0,878; 0,941; 1,0; 1,13; 1,272; 1,414; 1,618; 1,732; 2,058; 2,236; 2,618\}$$

3 Postęp prac – status etapów

Tabela 1: Status realizacji poszczególnych etapów projektu

Etap	Status	Uwagi
Pobranie i oczyszczenie danych cenowych	Ukończony	30 tickerów, 10 lat, 2514 sesji/ticker
Wyznaczenie lokalnych minimów i maksimów	Ukończony	Algorytm <code>argrelextrema</code>
Wyznaczanie trendów wzrostu/spadku	Ukończony	Sekwencje swing high/low
Wyznaczenie poziomów Fibonacciego	Ukończony	24 poziomy
Generowanie stref wsparcia i oporu	Ukończony	Strefy agregowane
Wizualizacja wyników	Ukończony	Wykresy świecowe z oznaczeniami
Tworzenie zbioru danych – etykietowanie stref	Ukończony	Etykiety: trafiona / nietrafiona
Wyznaczenie cech wejściowych	Ukończony	22 cechy (RSI, ATR, MACD, BB, ...)
Normalizacja / standaryzacja danych	Ukończony	<code>StandardScaler</code> dla SVM/LR
Podział danych treningowy/testowy	Ukończony	Podział chronologiczny 80/20
Oversampling (SMOTE)	Ukończony	<code>sampling_strategy=0.5</code>
Trening i porównanie modeli klasyfikacyjnych	Ukończony	RF, DT, SVM, LR, XGBoost
Strojenie hiperparametrów (GridSearchCV)	Ukończony	<code>TimeSeriesSplit</code> , $n = 5$
Analiza ważności cech	Ukończony	Wykres <i>feature importance</i>
Rozszerzenie zbioru danych	W trakcie	Więcej tickerów / dłuższe okresy
Sieci neuronowe (MLP, LSTM)	Planowany	Kolejny etap prac
Optymalizacja modeli	Planowany	Kolejny etap prac

4 Opis zrealizowanych etapów

4.1 Pobranie i oczyszczenie danych cenowych

Dane pobrano za pomocą biblioteki `yfinance` dla 30 instrumentów finansowych: spółek technologicznych (AAPL, MSFT, GOOGL, AMZN, META, TSLA, NVDA, AMD), indeksów (SPY, QQQ, DIA, IWM, ^GSPC, ^IXIC), spółek finansowych (JPM, BAC, GS, V, MA), innych sektorów (JNJ, PFE, XOM, CVX, WMT, COST), krypto-ETF (BITO, GBTC) oraz spółek europejskich (ASML, SAP, NVO).

Każdy zbiór obejmuje 10-letni horyzont (2016–2026) w interwale dziennym (2514 sesji). W zbiorze nie stwierdzono brakujących wartości. Kolumny danych: `Date`, `Open`, `High`, `Low`, `Close`, `Volume`.

Standaryzacja (`StandardScaler`) została zastosowana dla modeli wymagających znormalizowanej przestrzeni cech (SVM, Regresja logistyczna).

4.2 Wyznaczenie lokalnych minimów i maksimów (swing points)

Do wykrywania lokalnych ekstremów cenowych zastosowano funkcję `argrelextrema` z biblioteki `scipy.signal` z parametrem $n = 5$ (okno 5 świec w każdą stronę). Wyróżniono dwa typy punktów: *swing high* (lokalne maksimum na podstawie kolumny `High`) oraz *swing low* (lokalne minimum na podstawie kolumny `Low`). Dla pojedynczego tickera wykrywano średnio ok. 145 punktów każdego typu.

4.3 Wyznaczanie trendów wzrostu i spadku

Trendy wyznaczano na podstawie kolejnych par swing pointów. Sekwencja *swing low* $\rightarrow$ *swing high* definiuje trend wzrostowy, a *swing high* $\rightarrow$ *swing low* – trend spadkowy. Dla każdego tickera zidentyfikowano średnio ok. 245 trendów.

4.4 Wyznaczenie poziomów Fibonacciego i generowanie stref

Dla każdego trendu wyznaczono ceny odpowiadające 24 poziomom Fibonacciego według wzoru:

$$\text{cena}(L) = \text{High} - (\text{High} - \text{Low}) \cdot L$$

gdzie $L \in \mathcal{L}$ to zbiór poziomów zdefiniowany w sekcji 2.

Strefy agregowane wyznaczano na podstawie $N = 3$ ostatnich trendów, grupując bliskie poziomy (tolerancja $\varepsilon = 2\%$) i przypisując każdej grupie dominujący poziom Fibonacciego. Każda strefa obowiązuje przez kolejnych $N_s = 20$ świec.

4.5 Etykietowanie stref

Strefa otrzymuje etykietę **trafiona**, jeśli cena dotknęła jej w oknie N_s świec oraz w ciągu kolejnych 5 świec nastąpiło odbicie co najmniej 3% w kierunku zgodnym z typem strefy (wsparcie $\rightarrow$ wzrost, opór $\rightarrow$ spadek). W przeciwnym razie strefa jest oznaczana jako **nietrafiona**.

4.6 Cechy wejściowe modelu klasyfikacyjnego

Dla każdej wyznaczonej strefy Fibonacciego obliczono 22 cechy wejściowe opisujące kontekst rynkowy w momencie jej aktywacji. Cechy podzielono na pięć grup tematycznych.

4.6.1 Cechy trendu źródłowego

typ_trendu Określa kierunek trendu, z którego wyznaczono strefę: wartość 1 oznacza trend wzrostowy (strefa działa jako wsparcie), wartość 0 – trend spadkowy (strefa działa jako opór). Cecha binarna umożliwiającą modelowi uwzględnienie asymetrii zachowania ceny przy wsparciach i oporach.

dlugosc_trendu

Liczba sesji (świec dziennych) od początku do końca trendu źródłowego. Dłuższy trend może wskazywać na silniejszy ruch kierunkowy, a co za tym idzie – potencjalnie istotniejsze poziomy Fibonacciego wyznaczone na jego podstawie.

zmiana_trendu

Procentowa zmiana ceny od punktu startowego do końcowego trendu, wyznaczona jako:

$$\Delta_{\text{trend}} = \frac{p_{\text{end}} - p_{\text{start}}}{p_{\text{start}}}$$

Duża wartość bezwzględna oznacza dynamiczny ruch i może sugerować silniejsze odbicia przy powrocie ceny do kluczowych poziomów.

zmiennosc_trendu

Stosunek średniej wartości ATR (ang. *Average True Range*) w trakcie trwania trendu do ceny w punkcie końcowym:

$$\sigma_{\text{trend}} = \frac{\overline{\text{ATR}_{\text{trend}}}}{p_{\text{end}}}$$

Wysoka wartość wskazuje na nerwowy, zmienny ruch, co może wpływać na precyzję wyznaczanych stref.

4.6.2 Cechy odległości i położenia ceny

odleglosc_od_strefy

Procentowa odległość ceny zamknięcia od ceny strefy w momencie aktywacji:

$$d_{\text{strefa}} = \frac{p_{\text{close}} - p_{\text{strefa}}}{p_{\text{strefa}}}$$

Duża wartość oznacza, że cena jest jeszcze daleko od strefy i nie dotknęła jej bezpośrednio. Druga najważniejsza cecha w modelu (ważność: 0,131).

odleglosc_od_sma20

Procentowa odległość ceny strefy od 20-dniowej prostej średniej kroczącej (SMA20):

$$d_{\text{SMA20}} = \frac{p_{\text{strefa}} - \text{SMA20}}{\text{SMA20}}$$

Strefy leżące blisko SMA20 są bliżej “wartości godziwej” rynku, co może wpływać na prawdopodobieństwo odbicia.

odl_od_swing_high

Procentowa odległość ceny strefy od ostatniego lokalnego maksimum (swing high) wyznaczonego przed aktywacją strefy:

$$d_{\text{SH}} = \frac{p_{\text{strefa}} - p_{\text{swing_high}}}{p_{\text{swing_high}}}$$

Najważniejsza cecha w modelu (ważność: 0,210). Mała odległość od swing high sugeruje, że strefa leży przy istotnym technicznie poziomie.

odl_od_swing_low

Procentowa odległość ceny strefy od ostatniego lokalnego minimum (swing low):

$$d_{\text{SL}} = \frac{p_{\text{strefa}} - p_{\text{swing_low}}}{p_{\text{swing_low}}}$$

Analogicznie do odl_od_swing_high, mierzy bliskość strefy względem ostatniego dna rynkowego.

bb_pozycja Relatywne położenie ceny strefy wewnątrz pasm Bollingera (BB), wyrażone w skali $[0, 1]$:

$$BB_poz = \frac{p_{strefa} - BB_{lower}}{BB_{upper} - BB_{lower}}$$

Wartość bliska 0 oznacza położenie przy dolnej wstędze (potencjalne wyprzedanie), bliska 1 – przy górnej (potencjalne wykupienie). Trzecia najważniejsza cecha (ważność: 0,112).

bb_szerokosc

Szerokość pasm Bollingera unormowana przez SMA20:

$$BB_szer = \frac{BB_{upper} - BB_{lower}}{SMA20}$$

Duże wartości wskazują na fazę wysokiej zmienności, małe – na konsolidację rynku.

4.6.3 Cechy wolumenu

wolumen_sredni

Średni wolumen obrotu z ostatnich 5 sesji przed aktywacją strefy. Wzrost wolumenu przy zbliżaniu się ceny do strefy może sygnalizować zainteresowanie rynku danym poziomem.

wolumen_w_trendzie

Średni wolumen obrotu z wszystkich sesji wchodzących w skład trendu źródłowego. Trendy z wysokim wolumenem mogą generować silniejsze strefy Fibonacciego.

vol_relacyjny

Stosunek wolumenu z ostatnich 5 sesji do wolumenu z poprzednich 20 sesji:

$$V_{rel} = \frac{\overline{V_{[-5,0]}}}{\overline{V_{[-25,-5]}}}$$

Wartość $V_{rel} > 1$ oznacza wzrost aktywności rynkowej, co może poprzedzać istotny ruch cenowy przy strefie.

4.6.4 Wskaźniki techniczne

rsi_wejscie

Wartość wskaźnika RSI (ang. *Relative Strength Index*) z okresu 14 sesji, wyznaczona w momencie aktywacji strefy. Przyjmuje wartości z przedziału $[0, 100]$, gdzie wartości poniżej 30 wskazują na potencjalne wyprzedanie rynku, a powyżej 70 – na wykupienie.

rsi_strefa Kategoryczna interpretacja RSI w trzech stanach:

$$rsi_strefa = \begin{cases} 1 & \text{jeśli } RSI < 35 \quad (\text{wyprzedanie}) \\ 0 & \text{jeśli } 35 \leq RSI \leq 65 \quad (\text{neutralnie}) \\ -1 & \text{jeśli } RSI > 65 \quad (\text{wykupienie}) \end{cases}$$

`atr_wejscie`

Wartość wskaźnika ATR (ang. *Average True Range*) z okresu 14 sesji w momencie aktywacji strefy. Mierzy średni dzienny zasięg ruchu cenowego – duże ATR oznacza szerokie wahania, co należy uwzględnić przy ocenie tolerancji stref.

`trend_sma` Binarny wskaźnik długoterminowego trendu na podstawie relacji średnich kroczących:

$$\text{trend_sma} = \begin{cases} 1 & \text{jeśli SMA20} > \text{SMA50} \\ 0 & \text{w przeciwnym przypadku} \end{cases}$$

`momentum5` Krótkoterminowy impet cenowy mierzony procentową zmianą ceny zamknięcia na przestrzeni ostatnich 5 sesji:

$$m_5 = \frac{p_{\text{close}}^{(0)} - p_{\text{close}}^{(-5)}}{p_{\text{close}}^{(-5)}}$$

Dodatni momentum może wspierać odbicie przy strefach wsparcia.

`macd_hist` Histogram MACD (ang. *Moving Average Convergence Divergence*), definiowany jako różnica między linią MACD a linią sygnału:

$$\text{MACD_hist} = \text{EMA}_{12}(C) - \text{EMA}_{26}(C) - \text{EMA}_9(\text{MACD})$$

Wartości dodatnie wskazują na rosnące momentum wzrostowe, ujemne – na momentum spadkowe.

4.6.5 Cechy Fibonacciego

`poziom_fib` Numeryczna wartość poziomu Fibonacciego przypisanego do strefy, np. 0,382; 0,618; 1,272. Cecha kluczowa – różne poziomy mogą cechować się różną skutecznością jako strefy wsparcia/oporu.

`ilosc_w_klastrze`

Liczba innych stref z tego samego trendu leżących w odległości $\pm 2\%$ od rozpatrywanej strefy. Duże skupisko poziomów (*confluence*) może wzmacniać sygnał, jednak w obecnym modelu cecha ta okazała się najmniej istotna (ważność: 0,012).

`ile_razy_testowany`

Liczba historycznych stref (wyznaczonych przed aktywacją bieżącej), których cena mieści się w odległości $\pm 1,5\%$ od ceny bieżącej strefy. Poziomy wielokrotnie testowane historycznie mogą być silniejszymi strefami, lecz mogą być też już “zużyte” przez rynek.

4.6.6 Podsumowanie ważności cech

Tabela 2 przedstawia ważność cech wyznaczoną przez model Random Forest po strojeniu hiperparametrów.

Tabela 2: Ważność cech wejściowych – Random Forest (GridSearch)

Rank	Cecha	Ważność
1	odl_od_swing_low	0,210
2	odleglosc_od_strefy	0,131
3	bb_pozycja	0,112
4	rsi_wejscie	0,082
5	momentum5	0,071
6	atr_wejscie	0,068
7	zmiana_trendu	0,063
8	vol_relatywny	0,057
9	bb_szerokosc	0,051
10	odl_od_swing_high	0,049
11	poziom_fib	0,046
12	macd_hist	0,042
13	odleglosc_od_sma20	0,038
14	zmiennosc_trendu	0,034
15	wolumen_w_trendzie	0,031
16	ile_razy_testowany	0,028
17	wolumen_sredni	0,025
18	rsi_strefa	0,022
19	trend_sma	0,018
20	bb_pozycja	0,015
21	typ_trendu	0,013
22	dlugosc_trendu	0,012
23	ilosc_w_klastrze	0,012

Trzy cechy o najniższej ważności (*ilosc_w_klastrze*, *dlugosc_trendu*, *typ_trendu*) są kandydatami do usunięcia w ramach redukcji wymiarowości na kolejnych etapach projektu.

4.7 Podział danych i oversampling

Dane podzielono **chronologicznie** (80% trening, 20% test) w obrębie każdego tickera z osobna, a następnie złączono. Łącznie:

- Zbiór treningowy: 32 670 próbek
- Zbiór testowy: 8 181 próbek

Ze względu na silną nierównowagę klas (patrz sekcja 5) zastosowano technikę SMOTE (*Synthetic Minority Oversampling Technique*) z parametrem `sampling_strategy=0.5`.

4.8 Trening i porównanie modeli klasyfikacyjnych

Wytrenowano pięć modeli klasyfikacyjnych:

Tabela 3: Porównanie modeli klasyfikacyjnych na zbiorze testowym

Model	Dokładność	F1 (trafiona)	Recall	Precision
Random Forest	0,89	0,47	0,59	0,39
Drzewo decyzyjne	0,87	0,33	0,41	0,28
SVM	0,83	0,42	0,76	0,29
Regresja logistyczna	0,80	0,39	0,79	0,26
XGBoost	0,91	0,43	0,42	0,45
RF + GridSearch	0,90	0,47	0,56	0,41

Najlepsze parametry Random Forest wyznaczone przez GridSearchCV (TimeSeriesSplit, $k = 5$): `max_depth=10`, `max_features='sqrt'`, `min_samples_leaf=3`, `n_estimators=200`. Analiza ważności cech wskazała trzy najistotniejsze: `odl_od_swing_low` (0,210), `odleglosc_od_strefy` (0,131), `bb_pozycja` (0,112).

5 Aktualny problem: dysproporcja klas

Głównym wyzwaniem na obecnym etapie jest **silna nierównowaga klas** w zbiorze danych. Na poziomie całego zbioru stosunek klas wynosi:

$$\frac{\text{nietrafiona}}{\text{trafiona}} \approx \frac{29821}{2849} \approx 10,5 : 1 \quad (\text{zbiór treningowy})$$

Konsekwencją tej dysproporcji jest charakterystyczny wzorzec wyników – wysokie wartości ogólnej dokładności (*accuracy*) przy jednocześnie niskich wartościach F1-score dla klasy mniejszościowej. Przykładowo dla Random Forest: **accuracy = 0,89**, ale **F1 = 0,47**. Model dominująco przewiduje klasę większościową (“nietrafiona”), co daje pozornie dobrą ogólną dokładność, lecz słabą zdolność wykrywania rzeczywistych odbić ceny.

Zastosowane dotychczas metody łagodzenia problemu:

- parametr `class_weight='balanced'` w modelach scikit-learn,
- technika SMOTE (`sampling_strategy=0.5`),
- optymalizacja progu decyzyjnego (próg 0,68 zamiast domyślnego 0,5).

Wyniki poprawiły się, jednak F1-score pozostaje na poziomie 0,47, co wskazuje na konieczność dalszych działań.

6 Planowane dalsze kroki

6.1 Rozszerzenie zbioru danych

Pierwszym planowanym działaniem jest zwiększenie ilości danych treningowych poprzez:

- dodanie kolejnych tickerów (więcej rynków, więcej klas aktywów),
- rozszerzenie horyzontu historycznego (powyżej 10 lat, tam gdzie dostępne),
- uwzględnienie danych intraday (interwały 1h, 4h) w celu wygenerowania większej liczby przykładów klasy mniejszościowej.

6.2 Sieci neuronowe

Planowane jest zbadanie skuteczności architektur głębokiego uczenia, w szczególności:

- **MLP** (*Multi-Layer Perceptron*) – jako punkt odniesienia dla modeli “płytkich”,
- **LSTM** (*Long Short-Term Memory*) – do modelowania sekwencyjnego charakteru danych czasowych,
- **1D CNN** – do wykrywania lokalnych wzorców w szeregach czasowych.

6.3 Dalsze kroki metodologiczne

- Analiza Focal Loss jako alternatywy dla SMOTE przy nierównowadze klas.
- Walidacja krzyżowa z podziałem *walk-forward* (bardziej realistyczna symulacja handlu w czasie rzeczywistym).
- Ewaluacja modeli nie tylko pod kątem F1, ale też zysku hipotetycznej strategii transakcyjnej (backtesting).

7 Podsumowanie

Zrealizowano wszystkie kluczowe etapy przetwarzania danych, wyznaczania stref Fibonacciego oraz budowy pierwszych modeli klasyfikacyjnych. Najlepszy dotychczasowy wynik to $F1 = 0,47$ (Random Forest z GridSearch).

Zidentyfikowany problem dysproporcji klas wyznacza kierunek dalszych prac: rozszerzenie zbioru danych oraz eksploracja architektur sieci neuronowych, które mogą lepiej modelować nieliniowe zależności w danych finansowych przy jednoczesnym radzeniu sobie z nierównoważnymi zbiorami.